Candidato: Martha Domínguez Orduño

Descripción: Desarrollar un pipeline de análisis de datos utilizando los datos abiertos de la Ciudad de México correspondientes a la ubicación de las unidades del metrobús durante la última hora para obtener un histórico de la posición en la que se encuentra cada unidad que pueda ser consultado mediante un API Rest filtrando por unidad o por alcaldía.

Arquitectura de la solución:



Stack tecnológico: Elastic Stack

ELK Stack (o Elastic Stack) es un conjunto de herramientas open source desarrolladas por Elastics que permite recoger datos de cualquier tipo de fuente y en cualquier formato para realizar búsquedas, análisis y visualización de los datos en tiempo real.

Docker Compose

Con Compose puedes crear diferentes contenedores y al mismo tiempo, en cada contenedor, diferentes servicios, unirlos a un volúmen común, iniciarlos y apagarlos, etc. Es un componente fundamental para poder construir aplicaciones y microservicios.

Fuente

De la fuente obtenemos los datos crudos en formato json sobre las ubicaciones del Metrobús de la Ciudad de México, los datos lucen de la siguiente forma:

```
Ciudad de México, los datos lucen de la siguiente forma:

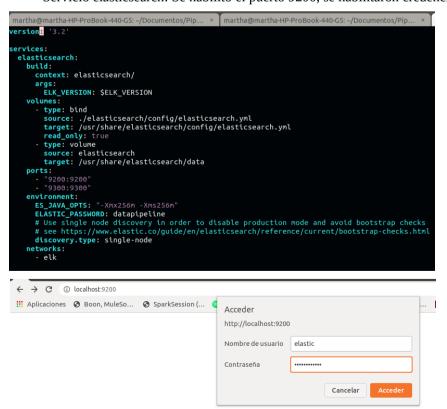
{nhits'; 207, "parameters': {dataset': "pruba fetchdata metrobus" 'timezona': "UTC': "fost": 10. "format': "jaon'), "recorde': [{datasetid': "pruba fetchdata metrobus" timezona': "UTC': "fiel fost": 10. "format': "jaon'), "recorde': [{datasetid': "200-09-30 22:09:15", "position longitude': -99.1877975463877, "trip schedule relationship': 2. "position speed': 16, "position latitude': 19.317499160766, trip route_id': "357", "vehicle label': "112", "position longitude': -99.187797546387, 19.317499160767]), "record timestamp': "2020-10-01103:09:16.345000+00:00"), "datasetid': "prueba fetchdata metrobus", "recordid': "8504c423a11034664596557-frocer738108484", "fields': ("vehicle did': 177", "trip start date': "2020-20-931220851", "position longitude': -99.17749786376553, "trip schedule relationship': 0, "position speed': 13, "position latitude': 19.32260863171367, "trip schedule relationship': 0, "position speed': 177", "position latitude': 19.3226086371367, "trip schedule relationship': 0, "position speed': 177", "trip schedule relationship': 2, "position speed': 0, "position latitude': 19.32260863713653, "trip schedule relationship': 2, "position speed': 0, "position latitude': 19.32260863713653, "trip schedule relationship': 2, "position speed': 0, "position longitude': 99.0473022460937, "trip schedule relationship': 2, "position speed': 0, "position longitude': 99.0473022460937, "trip schedule relationship': 2, "position speed': 0, "position longitude': 99.0473022460937, "trip schedule relationship': 2, "position dometer': 40, "vehicle label': 1239, "position longitude': 99.0473022460937, "trip schedule relationship': 0, "position longitude': 99.0473022460941), "geometry': (type: "Point', "coordinates': 19.308004760742, "position dometer': 10, "vehicle label': 1239, "position dometer': 10, "vehicle label': 1239, "position dometer': 0, "position dometer': 0, "position longitude': 99.05906476942,", "recordid: 19.32666749422," trip schedule relationship': 0,
```

https://datos.cdmx.gob.mx/api/records/1.0/search/?dataset=prueba fetchdata metrobus&q=

Mediante la herramienta docker-compose se levantaron los servicios del stack elastic con las siguientes configuraciones.

docker-compose.yml

Servicio elasticsearch: Se habilitó el puerto 9200, se habilitaron credenciales de acceso



Servicio corriendo

Servicio logstash: se habilitaron puertos de acceso - "5000:5000/tcp", - "5000:5000/udp" y "9600:9600", se especificó la red elk que se levanta con los servicios, es un servicio dependiente de elasticsearch

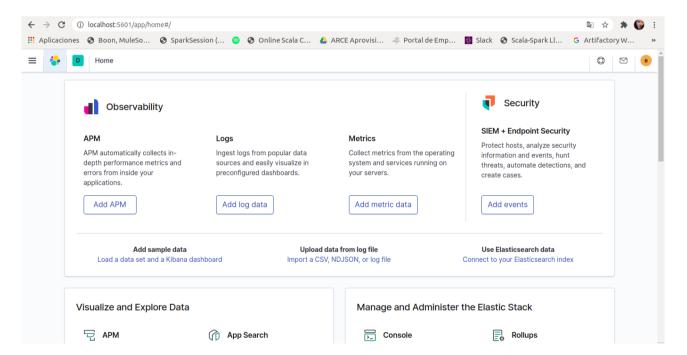
```
martha@martha-HP-ProBook-440-G5: ~/Documentos/Pip...
                                                              × martha@ma
  logstash:
    build:
       context: logstash/
       args:
         ELK_VERSION: $ELK_VERSION
    volumes:
        type: bind
         source: ./logstash/config/logstash.yml
target: /usr/share/logstash/config/logstash.yml
          read_only: true
         source: ./logstash/pipeline
target: /usr/share/logstash/pipeline
read_only: true
         type: bind
    ports:
- "5000:5000/tcp"
- "5000:5000/udp"
- "9600:9600"
    environment:
       LS_JAVA_OPTS: "-Xmx256m -Xms256m"
    networks:
       - elk
    depends_on:
        - elasticsearch
```

Servicio corriendo

Servicio Kibana: se especificó la red elk que se levanta con los servicios, es un servicio dependiente de elasticsearch, se especificó el puerto de acceso 5601

```
kibana:
build:
       context: kibana/
      args:
         ELK_VERSION: $ELK_VERSION
    volumes:
       - type: bind
         source: ./kibana/config/kibana.yml
target: /usr/share/kibana/config/kibana.yml
         read_only: true
    ports:
- "5601:5601"
    networks:
       - elk
    depends_on:
       - elasticsearch
networks:
 elk:
    driver: bridge
volumes:
elast<mark>i</mark>csearch:
```

Servicio corriendo



Configuraciones individuales:

```
elasticsearch.yml
```

```
martha@martha-HP-ProBook-440-G5: ~/Documentos/Pip... × martha@martha-HP-ProBook-440-G5: ~/Documentos/Pip... * martha@mart
```

kibana.yml

```
martha@martha-HP-ProBook-440-G5:~/Documentos/Pip... × martha@martha-HP-ProBook-440-G5:~/Documentos/Pip
```

logstash.yml

```
martha@martha-HP-ProBook-440-G5: ~/Documentos/Pip... × martha@mart
```

Ingesta

Logstash, uno de los productos principales del Elastic Stack, se usa para agregar y procesar datos y enviarlos a Elasticsearch. Logstash es una pipeline de procesamiento de datos open source y del lado del servidor que te permite ingestar datos de múltiples fuentes simultáneamente y enriquecerlos y transformarlos antes de que se indexen en Elasticsearch

Logstash se basa en el uso de plugins que soportan los distintos elementos de la herramienta mencionados: entradas, códecs, filtros y salidas.

Logstash dispone de un gran conjunto de plugins para la entrada de datos:

Beats: datos de Elastic Beats

Elasticsearch: resultados de consultas a Elasticsearch

Exec: salida de comandos

File: ficheros

http: datos recibidos por http o https

jdbc: datos de BBDD

pipe: datos de un comando pipe tcp: datos recibidos por un socket tcp

Se creó un Pipeline de logstash para ingestar datos a elasticsearch como se muestra a continuación.

```
martha@martha-HP-ProBook-440-G5: ~/Documentos/Pip..
                                                          martha@martha-HP-ProBook-440-G5: ~/Documentos/Pip..
                                                                                                                     martha@marl
nput {
 http_poller {
   urls => {
      urlname => "https://datos.cdmx.gob.mx/api/records/1.0/search/?dataset=prueba fetchdata metrobus&q="
   request_timeout => 60
   schedule => { every => "20s" }
codec => "line"
ilter {
   json{
     source => "message"
     remove_field => ["[message]"]
utput {
elasticsearch {
   index => "pipeline_base"
hosts => "elasticsearch:9200"
   user => "elastic
   password => "datapipeline"
codec => "json"
```

Dentro del flujo se tiene el **input**, donde se especifica con la ayuda del plugin http_poller la url de donde se ingestará la información, en este caso los datos abiertos de la Ciudad de México para la información del metrobus, se le dió un tiempo de respuesta de 60 segundos, y una consulta a la fuente de cada 20 segundos, se especificó mediante codec la representación de la información de entrada que en este caso será en line. La siguiente parte del flujo es **filter** donde se manipula el archivo con el plugin json, indicando que en la fuente "message" tenemos información sobre los records y posteriormente se elimina la etiqueta [message] para que no se almacene como un registro. La última parte del flujo **output** con la ayuda del plugin elasticsearch se especifica donde se almacenará la información con un nombre de índice, un nombre de host que en éste caso es del

elasticsearch levantado para la prueba, se le información credenciales de acceso y la reprensentación de la información de salida en formato json.

Una vez que se levanta el docker la ingesta se lleva a cabo creando así un índice que será almacenado en elasticsearch



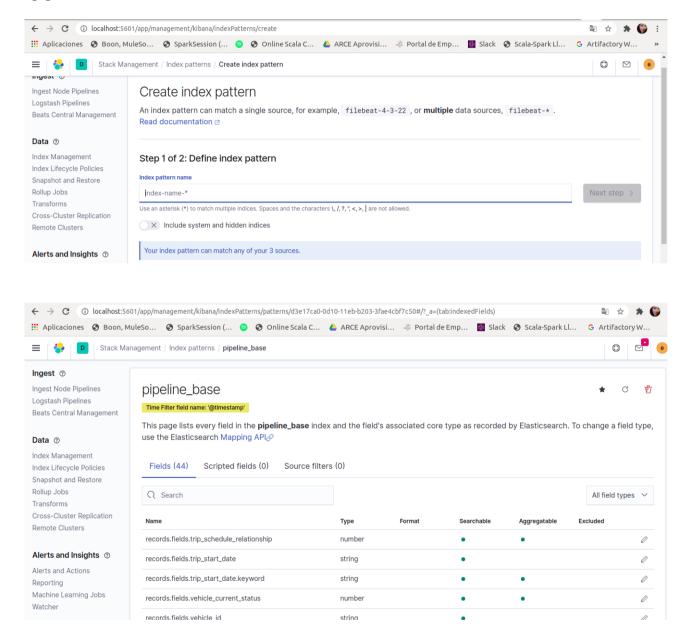
Almacenamiento

Para el almacenamiento de los datos se utliza la herramienta elasticsearch la cual proporciona una API RESTful para la comunicación con las aplicaciones del cliente. Por lo tanto, las llamadas REST se usan para ingestar datos, realizar búsquedas y analíticas de datos, así como también administrar el cluster y sus índices. Internamente, todos los métodos descritos recurren a esta API para ingestar datos en Elasticsearch, en el clúster antes descrito se tienen tres nodos los cuales entre otras funcionalidades nos brindan el almacenamiento de los datos para posteriormente realizar el procesmiento de los datos con Kivana Dev Tools.

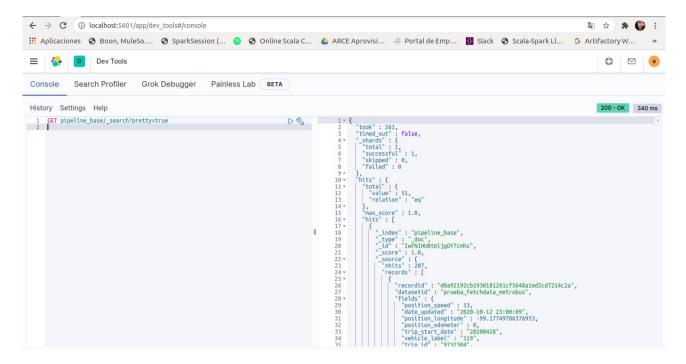
Información almacenada en elasticsearch

Análisis y visualización

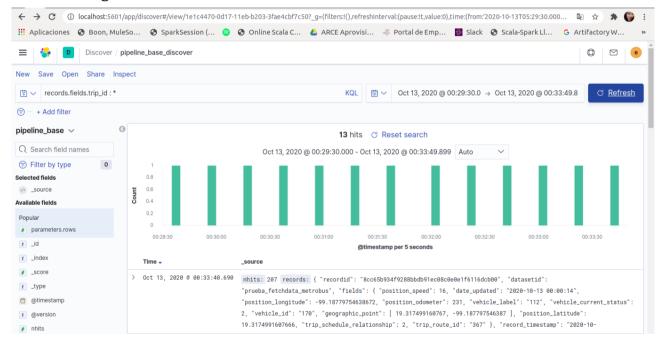
Para la visualización de la información de una forma gráfica se utiliza la herramienta Kibana donde se agregan los índices referentes a la información que se desea consultar, aquí se creó el índice nombrado desde el pipeline de logstash y que se almacenó en elasticsearch "pipeline_base"



Información sin graficar



Información graficada



https://github.com/Marth4011/pipeline.git → (Rama master)

Se levantan los servicios con el comando → sudo docker-compose up

(Se debe tener previamente instalado Docker)

Credenciales para acceder a los servicios:

username: elastic password: datapipeline

Dentro de la carpeta existe un README general que describe las secciones de configuración de los servicios en docker a detalle, requerimientos, ligas a información importante sobre el stack elastic, etc.

```
martha@martha-HP-ProBook-440-GS:-/Documentos/Pip... × martha@martha-HP-ProBook-440-GS:-/Documentos/Pip... / martha@martha-HP-ProBook-440-GS:-/Documentos/Pip
```